解耦安全：可验证性与约束投影的系统级定理化框架（定理2论文草稿）

匿名作者
匿名机构
anon@example.com

Abstract

本文严格化“解耦安全：可验证性与约束投影”中的两项核心结论：（i）将安全验证对象从生成分布切换为已生成实例，可将安全验证从全局不可判定问题降维为实例级可判定/多项式时间问题；（ii）将安全干预表述为向安全集合的约束投影，并给出其在有界离散输出空间中的存在性与复杂性边界。全文仅使用严密的数学语言（Definition/Lemma/Theorem/Proof）给出定理化陈述与证明。

1 预备定义（忠于原文的形式化对象）

定义 1 (输入/输出空间与生成器)**.** 令输入空间为 $\mathcal{X}$，输出空间为 $\mathcal{Y}$。生成器（基础模型）是映射

$$M : \mathcal{X} \to \mathcal{D}(\mathcal{Y}),$$

其中 $\mathcal{D}(\mathcal{Y})$ 表示 $\mathcal{Y}$ 上的概率分布集合；对 $x \in \mathcal{X}$，模型输出候选 $y \sim M(x)$。

定义 2 (安全谓词与安全集合)**.** 给定二元谓词 $\mathsf{Safe} : \mathcal{X} \times \mathcal{Y} \to \{0,1\}$。对任意输入 x，定义安全集合

$$C(x) \triangleq \{y \in \mathcal{Y} \mid \mathsf{Safe}(x,y) = 1\}.$$

定义 3 (可判定函数类)**.** 若函数（算子）f 能由确定性图灵机在有限时间内计算完成，且对相同输入总产生确定输出，则称 f 属于可判定函数类，记作 $f \in \mathsf{Dec}$。

定义 4 (解耦安全算子（安全判定/修正算子）)**.** 解耦安全算子是函数

$$S : \mathcal{X} \times \mathcal{Y} \to \mathcal{Y}.$$

我们要求 $S \in \mathsf{Dec}$，并要求其满足正确性（*soundness*）：

$$\forall x \in \mathcal{X},\ \forall y \in \mathcal{Y},\ \mathsf{Safe}(x, S(x,y)) = 1.$$

2 定理A：实例级可验证性（复杂性降维）

定义 5 (实例级验证问题)**.** 给定确定性算法（判定器）$D : \mathcal{X} \times \mathcal{Y} \to \{0,1\}$，实例级安全验证问题是：对输入 (x,y) 计算 $D(x,y)$ 并在有限时间内返回。

定理 1 (定理A：实例级可验证性)**.** 若存在安全判定算子（判定器）$D \in \mathsf{Dec}$，则对任意给定实例 (x,y)，命题“$\mathsf{Safe}(x,y) = 1$”在有限时间内可判定；若 D 的运行时间被某个多项式 $\mathrm{poly}(|x| + |y|)$ 上界，则实例级判定为多项式时间。

Proof. 由 $D \in \mathsf{Dec}$ 的定义，D 在任意输入 (x,y) 上必停机并输出确定值，因此判定在有限时间内完成。若进一步给出时间上界为 $\mathrm{poly}(|x| + |y|)$，则判定在多项式时间内完成。 □

3 约束投影：几何表述与存在性

定义 6 (约束投影算子)**.** 给定成本函数 $d_x : \mathcal{Y} \times \mathcal{Y} \to \mathbb{N}$（依赖于 x 的距离/代价），定义投影算子

$$\Pi_C(x,y) \in \arg\min_{y' \in C(x)} d_x(y, y').$$

定理 2 (定理B：投影算子的存在性)**.** 假设对任意 x，$C(x)$ 非空。进一步假设我们只考虑有界输出空间 $\mathcal{Y}_{\le T} \subseteq \mathcal{Y}$，使得对任意 x，集合 $C(x) \cap \mathcal{Y}_{\le T}$ 有限且非空，并且 $d_x(y,\cdot)$ 在该集合上取值于 $\mathbb{N}$。则对任意 x 与任意 $y \in \mathcal{Y}_{\le T}$，投影 $\Pi_C(x,y)$ 存在。

Proof. 集合 $C(x) \cap \mathcal{Y}_{\le T}$ 有限非空，函数 $d_x(y,\cdot)$ 在其上取有限个自然数值，必存在最小值并由某个元素取得；任取一个最小值的取得点即为投影输出。 □

引理 1 (投影的安全性（由定义直接推出）)**.** 在定理2的前提下，任意投影输出 $y' \in \Pi_C(x,y)$ 都满足 $\mathsf{Safe}(x,y') = 1$。

Proof. 由投影定义6可知 $y' \in C(x)$，再由安全集合定义2得 $\mathsf{Safe}(x,y') = 1$。 □

参考文献（占位）

References

[1] A. M. Turing. On computable numbers, with an application to the Entscheidungsproblem. *Proceedings of the London Mathematical Society*, 1936.

[2] H. G. Rice. Classes of recursively enumerable sets and their decision problems. *Transactions of the American Mathematical Society*, 1953.

[3] B. Alpern and F. B. Schneider. Defining liveness. *Information Processing Letters*, 1985. (安全/活性分解经典结果)